Justificación de la optimización del controlador difuso de semáforos

Cómo se hizo y por qué se eligió el controlador FLC-O

Documento de apoyo para la revisión del artículo «Mejora de un controlador de semáforos de lógica difusa para una intersección aislada: optimización del controlador de Pappis y Mamdani (1977)»

Raul Nolberto Quispe Saya y Kevin Luis Valero Ccacya
Escuela Profesional de Ingeniería Electrónica, Universidad Nacional de San Agustín de Arequipa

1. Resumen

Este documento responde a dos preguntas que plantea el artículo: ¿cómo se optimizó el controlador? y ¿por qué se eligió, entre varias alternativas, el controlador FLC-O? Todas las cifras salen de los resultados guardados en el repositorio (`resultados/opt/`) y se regeneran con `codigo/gen_justificacion.py` y `codigo/gen_tablas_opt.py`.

En una frase. Se buscó un controlador difuso mejor que el de Pappis y Mamdani (1977) con un procedimiento que no deja lugar a trampas de medición: un simulador exacto, un objetivo que cuenta toda la espera, tres grupos de escenarios separados (entrenar, elegir y probar) y rivales afinados con el mismo presupuesto. Se probaron cinco familias de candidatos y se eligió FLC-O porque fue el mejor en el grupo reservado para elegir, rindió igual o mejor que una red neuronal tres veces más grande conservando 27 reglas legibles, y su ventaja se mantuvo en cuatro conjuntos de prueba que nunca se usaron para entrenar.

Qué se hizo, en cinco pasos.

1. Se corrigió la medida del retardo para que cuente toda la espera hasta el final de la simulación (Sec. 4.1).
2. Se reescribió el simulador para evaluar cientos de escenarios a la vez, con resultados idénticos al simulador de referencia (Sec. 4.2).
3. Se definió un objetivo $J(\theta)$ y se optimizaron los parámetros con CMA-ES, un algoritmo evolutivo que no necesita derivadas (Sec. 4.3–4.4).
4. Se separaron los escenarios en entrenamiento, validación y prueba, y se afinaron con el mismo presupuesto los rivales (Sec. 4.5–4.6).
5. Se compararon cinco familias de candidatos y se eligió una con la validación, no con la prueba (Sec. 5–6).

Resultado. Retardo medio en s/veh con la vista adelante de 10 s que supone el modelo original:

Conjunto de prueba	Pappis	Actuado af.	FLC-O	FLC-O vs Pappis	FLC-O vs actuado
Oficial (16 pares × 20 réplicas)	10.95	9.63	7.91	−27.8 %	−17.8 %
64 caudales no vistos	10.40	9.17	7.40	−28.8 %	−19.3 %
Demanda variable	8.65	8.07	6.07	−29.8 %	−24.7 %
Cerca de la saturación	105.87	24.13	24.29	−77.1 %	empate (−0.7 %)

Fuente: `resultados/opt/evaluacion_final.json`; tabla del artículo generada por `codigo/gen_tablas_opt.py`.

Lo que no se afirma. (i) La mejora depende de la vista adelante de 10 s; sin ella el mejor controlador aprendido supera al actuado afinado solo en 1.7 %. (ii) Cerca de la saturación hay empate con el actuado afinado, no mejora. (iii) Todo es simulación; no hay datos de campo. Estos límites se detallan en la Sec. 10.

2. Punto de partida: qué se quería mejorar

El controlador de Pappis y Mamdani [1] gobierna una intersección aislada de dos calles unidireccionales. Interviene a los 7, 17, 27, 37 y 47 s de verde y, con 25 reglas, decide cuántos segundos (de 1 a 10) extender el verde o si cambiar de fase. La réplica previa de los autores lo reprodujo y dejó tres hechos que motivaron este trabajo:

1. Mejora al ciclo fijo de Webster en 16 de 16 combinaciones de caudal, como publicó el original.
2. La línea base de la Tabla VIII del original se llama «vehicle-actuated», pero sus retardos son los del ciclo fijo óptimo de su Tabla I, que el original supone equivalentes a los de un actuado eficiente (p. 709). Frente a un actuado por detector *simulado*, el controlador no es mejor en promedio (10.95 contra 10.89 s/veh en el conjunto oficial).
3. El original obtuvo sus reglas por prueba y error y habla de «satisficing control» (p. 714): un conjunto suficientemente bueno, no necesariamente el mejor.

La pregunta de investigación fue entonces: *¿cuánto puede mejorarse ese controlador si se optimizan sus parámetros y su estructura con un procedimiento reproducible, y contra qué referencias justas hay que medirlo?* El criterio de éxito adoptado fue ser mejor que el original y que un rival fuerte (el actuado afinado), en escenarios que no se usaron para entrenar.

3. Lo que dice el artículo original y lo que se decidió aquí

Como este trabajo ya no es una réplica, lo que el original no precisa se decide aquí y se declara como decisión propia. La tabla separa, con la página del original, lo que el artículo dice de lo que se hace en este trabajo.

Tema	Lo que dice el original	Lo que se hace aquí
Modelo (pp. 708–709)	Dos brazos unidireccionales sin giros; flujo de saturación de 3600 veh/h; tiempo perdido total de 10 s por ciclo; llegadas aleatorias decididas cada segundo comparando un número pseudoaleatorio con la tasa media; cada simulación, de 7200 s.	Igual. Precisiones propias: los 10 s por ciclo se reparten en 5 s por cambio de fase; un vehículo que llega a una cola vacía cruza sin esperar; paso de 1 s.
Retardo (pp. 708–709)	$d_m = D/\sum q_n$, con D la espera de cada ciclo, que suma segundo a segundo los vehículos en cola durante el rojo y el verde. No dice qué hacer con la cola que queda al terminar.	La misma definición aplicada a todo el horizonte, con la espera residual. La réplica anterior no la contaba.
Ciclo fijo de Webster (p. 709)	$c = (1.5L + 5)/(1 - Y)$ y verde repartido en proporción a y_i.	Idéntico.
Línea base de la Tabla VIII (pp. 707–709, 715)	La titula «vehicle-actuated», pero sus retardos son los de la Tabla I (ciclo fijo óptimo), que supone equivalentes a los de un actuado eficiente.	Se agrega un actuado por detector simulado y afinado, y se compara también con el ciclo fijo.
Detectores y vista adelante (pp. 709, 713)	Detectores lejos de la línea de parada informan de las llegadas a ambos brazos en los segundos siguientes (10 s por intervención).	Se mantiene esa vista adelante en los controladores que la usan y se mide cuánto depende de ella.
Intervenciones (pp. 709, 712–713)	Cada 10 s de verde, la primera a los 7 s; el verde efectivo máximo es de 57 s.	Igual en Pappis y Mamdani. FLC-O decide cada segundo, con verde máximo de 90 s.
Variables A y Q (pp. 710, 713)	A: vehículos que llegan al brazo con paso; Q: la cola. El ejemplo usa β_e y $\beta'_e = Q + \sum x'_i$ con vectores dados y no fija el cálculo en una simulación.	Definición propia (lectura calibrada), elegida entre ocho combinaciones por ser la única que reproduce el comportamiento publicado. Difiere del ejemplo en que Q cuenta solo los llegados desde el inicio del verde (Tabla S2 del suplemento).

Tema	Lo que dice el original	Lo que se hace aquí
Las 25 reglas (pp. 712–716)	Cinco por intervención, en el Apéndice. Obtenidas por prueba y error («satisficing control»), tras varias modificaciones del conjunto inicial (p. 714).	Pappis y Mamdani: intactas, como línea base. Pappis y Mamdani afinado: las mismas reglas con parámetros ajustados. FLC-O: 27 reglas nuevas.
Conjuntos difusos (p. 714)	Se modificaron las reglas y no los conjuntos, porque agregar sus parámetros como variables de decisión aumentaría radicalmente la dimensión del problema.	FLC-O aprende también sus conjuntos (9 nudos) con CMA-ES.
Decisión (pp. 713–714)	Se elige la extensión de mayor grado; si todos los grados son menores que 0.5 se cambia de fase; en un empate, la mayor extensión.	Idéntico en Pappis y Mamdani. FLC-O cambia de fase si $u > 0$.
Resultados (pp. 714–715)	Tabla VIII: el difuso mejora a su línea base entre 10 y 21 % en los 16 pares. Atribuye la mejora a los detectores lejos de la línea de parada, a detectar ambos brazos a la vez y al conjunto de reglas obtenido por prueba y error.	Se reproduce el comportamiento con un error medio de 9.2 % (máximo 18.6 %). La ablación coincide con la primera causa: la mayor parte de la mejora depende de la vista adelante.
Lo que no dice	Número de réplicas; generador aleatorio; cálculo de A y Q en simulación; qué hacer con la cola residual; reparto del tiempo perdido por cambio de fase; ajustes del actuado «eficiente».	Decisiones propias, declaradas en el artículo y su suplemento.

Fuente: C. P. Pappis y E. H. Mamdani, *A fuzzy logic controller for a traffic junction*, IEEE Trans. Syst., Man, Cybern., vol. SMC-7, no. 10, 1977 [1]; páginas de la revista. Lectura del original y de este trabajo hecha por los autores.

Por qué 25 reglas y por qué reglas nuevas. El controlador de 1977 se conserva con sus 25 reglas porque es el sistema que se quiere mejorar y la línea base de toda comparación: modificarlo confundiría qué mejora y cuánto. Las reglas nuevas de FLC-O son otro camino hacia la misma meta, y se justifican con dos hechos. El primero lo reconoce el propio original: sus reglas salen de prueba y error y no optimizó los conjuntos difusos por la dimensión del problema (p. 714). El segundo es la evidencia de este trabajo: afinar solo los números de las 25 reglas mejora 11.7 % y falla cerca de la saturación, mientras que cambiar la estructura (reglas nuevas que deciden cada segundo) mejora 27.8 %. No se probó un camino intermedio: conservar la estructura de las 25 reglas y optimizar también sus conjuntos difusos y consecuentes; es una extensión posible.

Las entradas A y Q son una decisión de este trabajo. El original las describe con un ejemplo pero no fija su cálculo en una simulación. Aplicadas al pie de la letra, el controlador se satura; se adoptó la única de las ocho lecturas razonables que reproduce el comportamiento publicado, y se declara como decisión propia y no como la implementación original.

4. Cómo se hizo la optimización

4.1. La medida de desempeño: el retardo que cuenta toda la espera

La medida es el retardo medio por vehículo

$$d_m = \frac{1}{N} \sum_{n=0}^{H-1} \left(Q_{1,n} + Q_{2,n} \right), \tag{1}$$

con N los vehículos llegados, H el horizonte (7200 s en las pruebas) y $Q_{i,n}$ la cola del brazo i en el segundo n. *Origen:* es la definición del original, que calcula la espera de cada ciclo sumando, segundo a segundo, los vehículos en cola durante el rojo y el verde (p. 708), aplicada a todo el horizonte. Cada vehículo en cola acumula un segundo de espera por segundo, así que sumar las colas suma las esperas; por la ley de Little [2], $L = \lambda W$, es equivalente a la espera media por vehículo. El original no dice qué hacer con los vehículos que siguen en cola al terminar la simulación. La réplica anterior de los autores solo contaba a los que ya habían salido; la diferencia es la espera de quienes siguen en la cola al terminar, y importa cuando el controlador deja crecer la cola:

	Oficial		Saturado	
	solo servidos (réplica)	con residuo	solo servidos (réplica)	con residuo
Pappis y Mamdani	10.93	10.95	99.46	105.87
FLC-O	7.90	7.91	24.22	24.29

Fuente: `resultados/opt/evaluacion_final.json`, campos `delay` y `delay_servidos`.

En el conjunto oficial la diferencia es mínima, pero cerca de la saturación la convención de la réplica oculta, en promedio por escenario, el 4.1 % del retardo de Pappis y Mamdani (hasta el 13.9 % en un escenario; el 6.1 % si se comparan los promedios de la tabla). Un objetivo que ignorara esa espera premiaría a un controlador que abandona colas. Por eso el artículo usa (1) y reporta aparte, en `resultados/opt/evaluacion_final.json`, la convención de la réplica.

4.2. El simulador vectorizado

Optimizar exige evaluar un controlador muchas veces. Con $\lambda = 15$ candidatos por generación, 150 generaciones y 64 escenarios, cada entrenamiento de FLC-O hace 144 000 simulaciones de 3600 s. Con el simulador de referencia (unos 230 ms por escenario de 7200 s, medido con el controlador de Pappis y Mamdani) eso son del orden de 4.6 h en un núcleo, y se necesitan varios entrenamientos. Se reescribió el simulador para simular n_e escenarios a la vez con arreglos de NumPy: unos 10 ms por escenario, unas veinte veces menos. Lo que hace válido el cambio es que la equivalencia es *exacta*: en 8 escenarios de 2400 s, con seis controladores y las dos convenciones de retardo, la diferencia es nula (`test_sim_batch.py`). El simulador interactivo con calle y autos usa la misma lógica y se comprueba contra este (`test_sim_flco.py`).

4.3. El objetivo

Para un vector de parámetros θ se minimiza

$$J(\theta) = \frac{1}{N_e} \sum_{i=1}^{N_e} \frac{d_m^{(i)}(\theta)}{d_m^{(i)}(\mathrm{act})}, \qquad N_e = 64, \tag{2}$$

la media, sobre 64 escenarios, del retardo del controlador dividido por el del actuado afinado en el *mismo* escenario (definición propia). Tres razones: (a) $J < 1$ significa «mejor que un rival fuerte», no solo «mejor que nada»; (b) todos los niveles de demanda pesan igual, porque sin dividir, los escenarios de mucho tráfico, con retardos grandes, dominarían el promedio y el controlador aprendería solo a manejarlos; (c) las llegadas de cada escenario son las mismas para todos los candidatos, de modo que la comparación entre dos candidatos no depende de la suerte de las llegadas.

4.4. El optimizador: CMA-ES

Los parámetros se optimizan con CMA-ES [3, 4], una estrategia evolutiva que mantiene una distribución normal sobre los parámetros, sortea candidatos, evalúa cada uno con (2) y usa los mejores para actualizar la media y la covarianza de la distribución. Se eligió porque el objetivo es una simulación con eventos discretos, sin derivadas utilizables, y porque con 30 a 121 parámetros es el rango en que este método se usa habitualmente; tiene pocos parámetros propios que ajustar. Configuración común: población $\lambda = 4 + \lfloor 3 \ln n \rfloor$ ($\lambda = 15$ para $n = 42$), $\mu = \lfloor \lambda/2 \rfloor = 7$ padres, paso inicial $\sigma_0 = 0.3$, 150 generaciones (de 80 a 200 según el modelo), evaluación en paralelo con 4 procesos y puntos de control cada 10 generaciones. Entrenar FLC-O toma unos 13 minutos (787 s el modelo elegido). La implementación es propia (`codigo/opt_es.py`) y se verifica con funciones de prueba conocidas (esfera y Rosenbrock, `test_opt.py`). No se comparó con otros optimizadores; es una decisión de diseño, no un resultado.

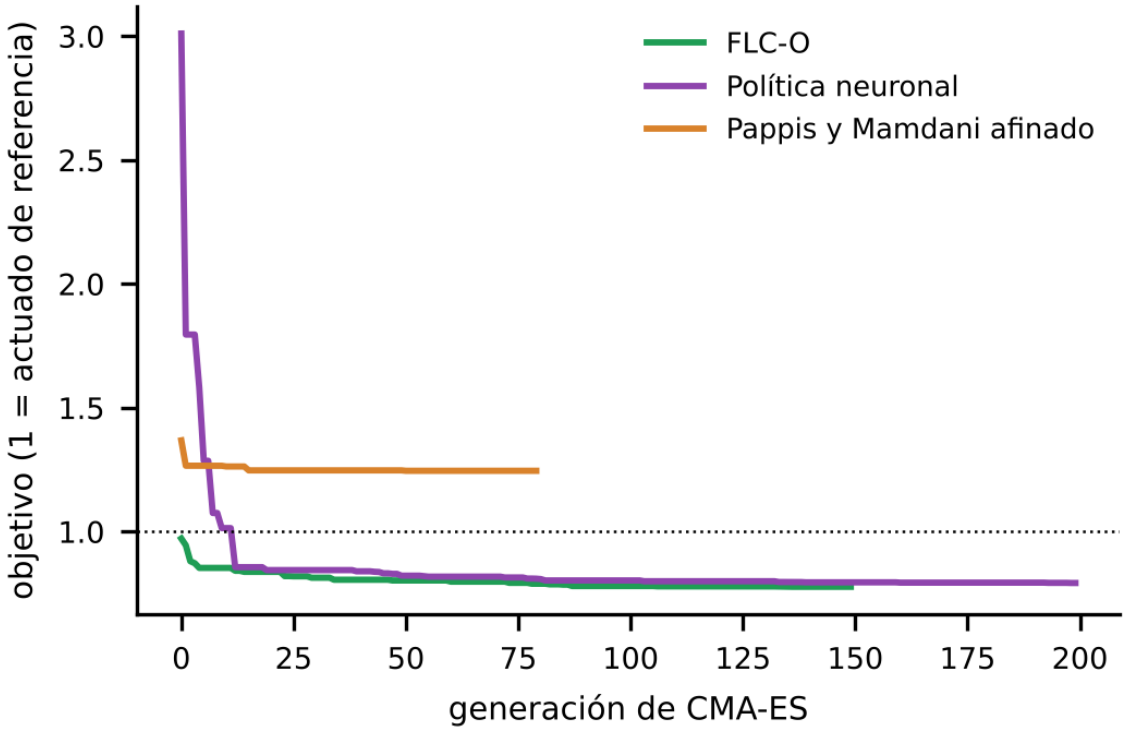


Fig. 1: Mejor valor del objetivo $J(\theta)$ por generación para los modelos finales (1: igual al actuado afinado de referencia; menos es mejor).

4.5. Tres grupos de escenarios que nunca se mezclan

Para que el resultado no sea un ajuste a los datos, cada decisión usa un grupo distinto:

Grupo	Contenido	Semillas	Para qué se usa
Entrenamiento	64 pares de caudales sorteados (cada brazo $\geq$ 180, suma de 540 a 3300 veh/h), 3600 s	100000 a 100063	Calcular J y entrenar
Validación	64 pares distintos, 7200 s	200000 a 200063	**Elegir** entre candidatos, el verde mínimo y la semilla
Prueba oficial	Los 16 pares de la Tabla VIII del original $\times$ 20 réplicas, 7200 s	0 a 19	Resultado principal
Prueba: no vistos	64 pares sorteados con otras semillas, 7200 s	500000 en adelante	Que no dependa de los 16 pares
Prueba: variable	64 escenarios con demanda que cambia cada 600 s (factor de 0.4 a 1.6), 7200 s	–	Demanda no estacionaria
Prueba: saturado	32 pares con suma de 3000 a 3300 veh/h, 7200 s	400000 en adelante	Cerca de la capacidad

Fuente: `codigo/opt_entrenar.py` y `codigo/opt_evaluar.py`; hiperparámetros en el suplemento del artículo.

Ningún conjunto de entrenamiento incluye los 16 pares de la Tabla VIII. Las elecciones de diseño (candidato, verde mínimo y semilla) se hicieron con la validación y no con la prueba, y los modelos finales no se reentrenaron a partir de los resultados de prueba. Los conjuntos de prueba se evaluaron con todos los candidatos, no solo con el elegido.

4.6. Rivales justos

Una mejora solo vale frente a un rival serio. Por eso, además del ciclo fijo de Webster y del actuado de la réplica, se afinaron dos controladores de la literatura con los mismos escenarios de entrenamiento, el mismo rango de verde mínimo (3 a 7 s) y el mismo verde máximo (hasta 90 s) que los controladores aprendidos:

- **Actuado afinado:** se probaron 45 configuraciones (hueco de 1 a 3 s, verde mínimo de 3 a 7 s, máximo de 57, 80 y 90 s). Resultó hueco de 1 s, mínimo de 3 s y máximo de 90 s, con un J de 0.823 respecto del actuado original: ya es un 17.7 % mejor que el original. Es el rival fuerte del artículo.
- **Presión máxima** [5]: afinada igual, da 17.44 s/veh. En este modelo, con dos fases y tiempo perdido, rinde peor que el actuado; se incluye como referencia de la literatura, no como rival fuerte.
- **Cota por programación dinámica** [6]: la política óptima para caudales *conocidos* y sin ver llegadas futuras. Da 9.35 s/veh y se valida contra la simulación de su propia política (diferencia máxima 0.7 %). Sirve como comprobación de coherencia (Sec. 8).

Un error que se detectó y corrigió. La primera rejilla del actuado exigía un verde mínimo de 5 s o más, lo que lo debilitaba frente a controladores que podían usar 3 s y favorecía al propuesto. Se amplió el rango a 3–7 s y el actuado mejoró un 5 % en el conjunto oficial; todas las cifras del artículo usan esta versión justa. Lo mismo se hizo con la presión máxima. Las rejillas anteriores se conservan en `resultados/opt/actuado_afinado_v1.json` y `resultados/opt/maxpressure_afinado_v1.json`.

5. Qué candidatos se probaron

Se entrenaron, con las mismas condiciones, cinco familias. Cada una responde a una pregunta distinta:

A. Pappis y Mamdani afinado (30 parámetros). *¿Basta con ajustar el controlador de 1977?* Conserva sus 25 reglas y su estructura y afina el umbral de decisión, una escala y un desplazamiento de las entradas A y Q, y un desplazamiento del conjunto de tiempo de cada regla. Con los valores del original reproduce exactamente al controlador replicado. Resultado: 9.67 s/veh (una mejora de 11.7 % respecto de Pappis y Mamdani) y, cerca de la saturación, 58.11 s/veh, más del doble que el actuado afinado: con la estructura de 1977 conservada, ajustar ayuda pero no es suficiente.

B. Difuso nuevo de 27 reglas con horizontes fijos (36 parámetros). *¿Ayuda cambiar la estructura: decidir cada segundo, con menos reglas?* Tres variables (demanda en verde G, presión en rojo R, verde transcurrido V) con tres conjuntos cada una. Resultado: 8.47 s/veh (media de tres semillas); ya supera con holgura a la familia A.

C. Difuso de 81 reglas con el hueco desde la última llegada (93 parámetros). *¿Más reglas y más información mejoran?* Agrega como cuarta variable el tiempo desde la última llegada al brazo con verde, la señal que usa el actuado. Resultado: 8.44 s/veh (media de tres semillas), sin mejora frente a las 27 reglas (8.47); la información adicional no aporta y los parámetros casi se triplican (de 36 a 93).

D. FLC-O (42 parámetros). *¿Se puede aprender también cuánto mirar hacia adelante?* Es la familia B con una modificación: las llegadas previstas que alimentan G y R son una combinación lineal, con pesos no negativos *aprendidos*, de las llegadas de los próximos 2, 5 y 10 s (verde) y 3, 6 y 10 s (rojo). Resultado: 7.98 s/veh (media de tres semillas, desviación estándar de 0.06), y 7.91 con la semilla elegida por validación.

E. Política neuronal (121 parámetros). *¿Cuánto se pierde por exigir reglas legibles?* Una red de una capa oculta con 8 neuronas que recibe 12 características y decide cada segundo. No es un

Tabla 2: Candidatos entrenados con las mismas condiciones: J de entrenamiento (3600 s, 64 escenarios) y de validación (7200 s, 64 escenarios distintos; 1 es igual al actuado afinado, menos es mejor) y retardo medio en los cuatro conjuntos de prueba (s/veh)

Candidato	Par.	Vista	J entr.	J val.	Oficial	No vistos	Variable	Saturado
Actuado afinado (referencia)	3	no	–	1	9.63	9.17	8.07	24.13
Pappis y Mamdani (1977)	0	10 s	–	–	10.95	10.40	8.65	105.87
Pappis y Mamdani afinado (25 reglas)	30	10 s	1.246	1.420	9.67	9.30	8.06	58.11
Difuso 27 reglas, horizontes fijos	36	10 s	0.826	0.837	8.44	7.88	6.56	24.80
Difuso 81 reglas con hueco	93	10 s	0.827	0.838	8.47	7.93	6.55	25.00
FLC-O, $g_{\text{mín}} = 7\,\text{s}$	42	10 s	0.860	0.899	8.60	8.14	6.85	25.15
FLC-O, $g_{\text{mín}} = 5\,\text{s}$	42	10 s	0.815	0.834	8.21	7.75	6.41	25.16
FLC-O, $g_{\text{mín}} = 4\,\text{s}$	42	10 s	0.795	0.807	8.04	7.58	6.20	24.38
FLC-O, $g_{\text{mín}} = 3\,\text{s}$, semilla 0	42	10 s	0.794	0.805	8.00	7.51	6.21	24.79
FLC-O, $g_{\text{mín}} = 3\,\text{s}$, semilla 1	42	10 s	0.788	0.807	8.04	7.49	6.24	24.63
FLC-O, $g_{\text{mín}} = 3\,\text{s}$, semilla 2 (elegido)	42	10 s	0.777	0.800	7.91	7.40	6.07	24.29
Política neuronal	121	10 s	0.793	0.809	8.09	7.53	6.24	25.10
Difuso 27 reglas, causal	36	no	0.982	1.065	9.97	9.37	8.41	25.74
Política lineal causal	16	no	0.949	0.992	9.53	8.97	8.10	25.11
Política neuronal causal	121	no	0.942	0.982	9.46	8.95	8.05	24.29

Fuente: `resultados/opt/evaluacion_final.json` (prueba), `codigo/opt_validar.py` (validación) y campo `fitness_train` de cada modelo de `resultados/opt/` (entrenamiento); tabla generada por `codigo/gen_justificacion.py`.

controlador propuesto, sino una referencia de lo que logra un aprendizaje sin estructura con la misma información, también con sus variantes sin vista adelante (causales).

6. Por qué se eligió FLC-O

6.1. Los criterios

Los dos primeros decidieron la elección y se aplicaron con la validación; los otros tres son comprobaciones con los conjuntos de prueba. En orden: (1) mejor J en validación; (2) a igual rendimiento, preferir el modelo con menos parámetros y con reglas que puedan leerse; (3) que la ventaja se mantenga en datos no vistos y con demanda variable; (4) que no se degrade cerca de la saturación; (5) que no dependa de la semilla de entrenamiento.

6.2. Las razones

1. **Fue el mejor en el grupo reservado para elegir.** En validación, FLC-O con $g_{\text{mín}} = 3\,\text{s}$ y la semilla 2 tiene $J = 0.800$, contra 0.809 de la red neuronal, 0.837 y 0.838 de las otras dos familias difusas y 1.420 de Pappis y Mamdani afinado (Tabla 2). La elección se hizo con esta columna, no con la de prueba.

2. **La legibilidad no cuesta rendimiento.** FLC-O no es peor que una red con 121 parámetros: 7.91 contra 8.09 s/veh en el conjunto oficial. Comparados por par de caudales con Wilcoxon pareado y corrección de Holm, FLC-O es significativamente mejor en 11 de 16 pares y en ninguno es peor (diferencia media de 2.5 %). El margen es pequeño y hay una asimetría que conviene decir: FLC-O es la mejor de tres semillas y la red es un solo entrenamiento; con el promedio de las tres semillas (7.98 s/veh) la ventaja sobre la red sigue, pero baja a 1.3 %. No se afirma que FLC-O sea mejor que cualquier red posible (Sec. 10); lo que sí muestra es que exigir 27 reglas legibles no obliga a rendir menos.

3. **Aprender la vista adelante aporta.** Con horizontes fijos, el mismo difuso de 27 reglas da 8.47 s/veh (media de tres semillas, desviación estándar de 0.04); con los pesos aprendidos, 7.98 (desviación estándar de 0.06), y cada semilla de FLC-O queda por debajo de cada una de las de horizontes fijos.
4. **Más reglas no ayudan.** La variante de 81 reglas da 8.44 s/veh (media de tres semillas, desviación estándar de 0.03), igual que las 27 reglas con horizontes fijos (8.47). Con 27 reglas, la base se puede leer entera en una tabla (Tabla 3).
5. **Generaliza.** El retardo de FLC-O es 0.822 veces el del actuado afinado en el conjunto oficial, 0.807 en los caudales no vistos y 0.753 con demanda variable. La brecha entre J de entrenamiento (0.777) y de validación (0.800) es de 2.9 %, pequeña para un modelo de 42 parámetros.
6. **No se degrada cerca de la saturación.** 24.29 s/veh frente a 24.13 del actuado afinado: empate. Pappis y Mamdani da 105.87 y su versión afinada 58.11.
7. **No depende de una semilla afortunada.** Se entrenó con tres semillas: en el conjunto oficial dan 8.00 (semilla 0), 8.04 (semilla 1) y 7.91 s/veh (semilla 2, la elegida). Si en lugar de la elegida por validación se tomara el promedio de las tres (7.98 s/veh), la reducción frente a Pappis y Mamdani sería de 27.1 %, y con la peor, de 26.6 %; la conclusión no cambia.

6.3. Cómo se eligió la configuración final

- **Verde mínimo:** se entrenó FLC-O con 3, 4, 5 y 7 s y se eligió con la validación: $J = 0.805$ (3 s), 0.807 (4 s), 0.834 (5 s) y 0.899 (7 s). Es el factor que más pesa (con tres semillas cada una: 8.55, 8.19, 8.05 y 7.98 s/veh para 7, 5, 4 y 3 s); entre 4 y 3 s la diferencia es del orden de la dispersión entre semillas. Si la norma local exige más de 3 s, con 5 s se conserva casi toda la mejora (8.19 s/veh, 25.2 % menos que Pappis y Mamdani en promedio de las semillas).
- **Semilla:** de las tres semillas con 3 s ($J = 0.805$, 0.807 y 0.800) se tomó la de menor J en validación. Esa semilla resultó también la de menor retardo en la prueba, pero la elección no se hizo mirándola.
- **Verde máximo de 90 s:** permite a los controladores aprendidos no depender del tope de 57 s de 1977, que limita a Pappis y Mamdani cerca de la saturación; el actuado afinado recibió el mismo tope.

7. Qué aprendió FLC-O (lectura del modelo)

Las 27 reglas tienen la forma «si G es $\mathcal{G}_i$ y R es $\mathcal{R}_j$ y V es $\mathcal{V}_k$ entonces c_{ijk}»; la salida es

$$u = \frac{\sum_{ijk} w_{ijk}\, c_{ijk}}{\sum_{ijk} w_{ijk}}, \qquad \text{cambiar de fase} \iff u > 0, \tag{3}$$

con w_{ijk} el producto de las tres pertenencias. *Origen:* es el centro de gravedad de consecuentes de un solo punto, un sistema de Mamdani con salidas *singleton* equivalente a uno de Takagi y Sugeno de orden cero [7]. Se eligió esta forma porque da una salida suave, que facilita el trabajo de CMA-ES, y a la vez cada regla dice con un número si conviene cambiar ($c > 0$) o seguir ($c < 0$).

Las entradas son $G = Q_g + \sum_k \omega_k W_g(l_k)$ y $R = Q_r + \sum_k \rho_k W_r(l'_k)$, con Q_g y Q_r las colas de los brazos en verde y en rojo, $W(l)$ las llegadas previstas en los l segundos siguientes ($l = 2, 5, 10$ en verde y $l' = 3, 6, 10$ en rojo) y $\omega_k, \rho_k \geq 0$ pesos que aprende el entrenamiento; V son los segundos de verde transcurridos. Los pesos aprendidos son $\omega = (0.88, 0.21, 0.03)$ y $\rho = (0.22, 0.88, 0.49)$. Como cada ventana contiene a la anterior, el peso efectivo de un vehículo según su segundo de llegada es:

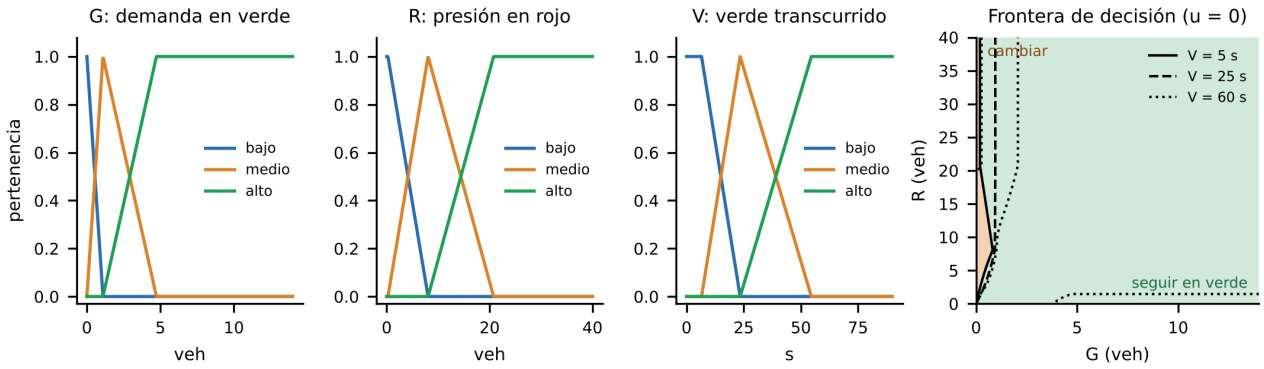


Fig. 2: Funciones de pertenencia aprendidas de FLC-O para G, R y V y frontera de decisión $u = 0$ en el plano (G, R) para tres valores de V.

Tabla 3: Base de reglas de FLC-O: consecuente numérico c_{ijk} de cada regla (positivo: cambiar la fase; negativo: seguir en verde) según la demanda en verde G, la presión en rojo R y el verde transcurrido V. Nudos (k_1, k_2, k_3): G (0.000, 1.095, 4.731), R (0.239, 8.048, 20.776), V (6.562, 23.457, 54.569). Pesos aprendidos de la vista adelante: verde (0.88, 0.21, 0.03) para 2, 5 y 10 s; rojo (0.22, 0.88, 0.49) para 3, 6 y 10 s.

G	R	V bajo	V medio	V alto
bajo	bajo	+0.06	+0.04	−0.16
bajo	medio	+1.52	+1.45	+2.37
bajo	alto	+0.34	+2.18	−0.19
medio	bajo	−2.75	−1.06	−1.09
medio	medio	−0.51	−0.27	−0.20
medio	alto	−1.61	−0.36	+0.60
alto	bajo	−0.52	−1.34	+0.33
alto	medio	−3.32	−2.08	−1.81
alto	alto	−2.04	−0.03	−1.62

Fuente: modelo entrenado flcopt_g3_s2 (resultados/opt/flcopt_g3_s2.json).

	primeros segundos	segundos intermedios	segundos lejanos
Verde (G)	s 1–2: 1.12	s 3–5: 0.24	s 6–10: 0.03
Rojo (R)	s 1–3: 1.58	s 4–6: 1.37	s 7–10: 0.49

Fuente: cálculo sobre los pesos del modelo `resultados/opt/flcopt_g3_s2.json`, hecho por `codigo/gen_justificacion.py`.

Interpretación (una lectura del resultado, no una demostración): para decidir si seguir en verde importan sobre todo los vehículos que llegarán en los próximos 2 s, que son los que aún aprovecharían el verde; para estimar la presión en rojo importan los que llegarán en los próximos 6 s, un horizonte parecido a los 5 s de tiempo perdido de cada cambio de fase. Los conjuntos aprendidos tienen sus nudos en $G = (0.00, 1.10, 4.73)$, $R = (0.24, 8.05, 20.78)$ y $V = (6.56, 23.46, 54.57)$ s. De los 27 consecuentes, 9 empujan a cambiar y 18 a seguir, con valores de -3.32 a 2.37. El patrón es el esperable: se cambia cuando ya queda poca demanda en verde y hay presión en rojo (fila G bajo, R medio: de $+1.45$ a $+2.37$), se sigue cuando la demanda en verde es media o alta (por ejemplo G alto, R medio: de -3.32 a -1.81), y también cuando ambos brazos están muy cargados, para no malgastar tiempo perdido.

8. Evidencias de que la mejora es real

1. **Datos separados.** Entrenar, elegir y probar usan escenarios y semillas distintos (Sec. 4.5).
2. **Significancia estadística por par.** En el conjunto oficial, FLC-O es significativamente mejor que Pappis y Mamdani en 16 de 16 pares y que el actuado afinado en 16, con corrección de Holm y sin ningún par peor (Wilcoxon pareado sobre 20 réplicas con números aleatorios comunes).

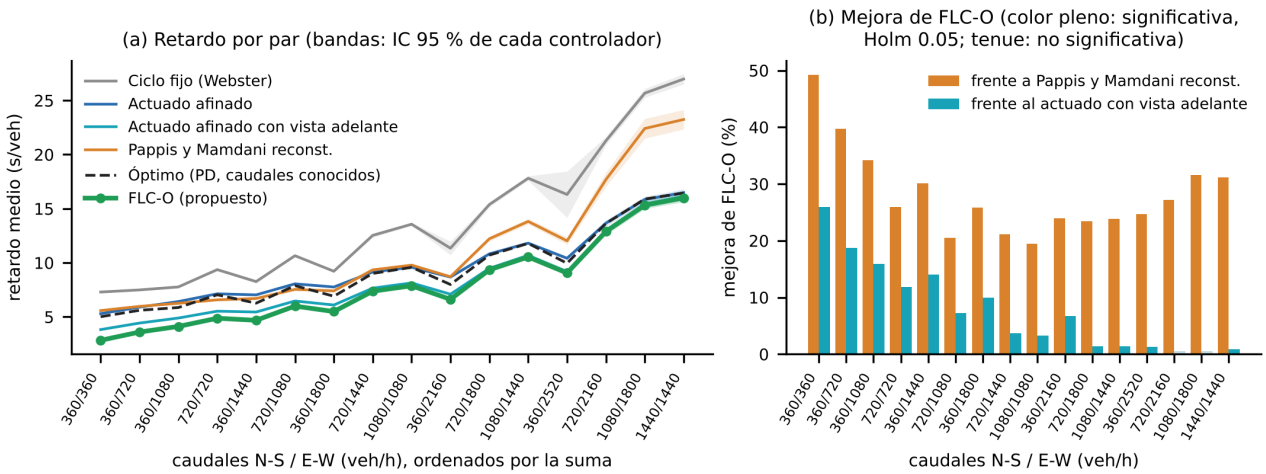


Fig. 3: (a) Retardo medio por par de caudales de la Tabla VIII (7200 s, 20 réplicas); la banda es el intervalo de confianza de 95 % de FLC-O. (b) Mejora de FLC-O frente a Pappis y Mamdani en cada par; en verde, las significativas con la corrección de Holm.

3. **Datos no vistos y demanda variable.** La reducción se mantiene: 28.8 % y 19.3 % con 64 caudales no vistos; 29.8 % y 24.7 % con demanda variable.
4. **Simulador exacto.** El simulador rápido da, escenario por escenario, el mismo retardo que el de referencia, así que ninguna ventaja viene de una simplificación del simulador.
5. **Comprobación de coherencia con la cota.** La cota por programación dinámica (9.35 s/veh) es el mejor retardo posible para quien conoce los caudales pero no ve el futuro. Todos los controladores *sin* vista adelante quedan por encima: la política neuronal causal da 9.46, la lineal causal 9.53, el actuado afinado 9.63 y el difuso causal 9.97. Es coherente con un entrenamiento que no explota atajos del simulador (no lo demuestra, pero un controlador sin vista adelante por debajo de la cota habría sido una señal de alarma). FLC-O queda por debajo de la cota porque sí ve las llegadas de los próximos segundos, no porque la cota falle.
6. **Rivales afinados con el mismo presupuesto**, y un error de rejilla que se corrigió en contra del propuesto (Sec. 4.6).
7. **Todo es reproducible** desde el repositorio (Sec. 12).

9. Qué se corrigió y se descartó en el camino

Se deja constancia porque ayuda a juzgar el procedimiento:

- **Rejilla del actuado** que favorecía al propuesto: corregida (Sec. 4.6).
- **La red neuronal ya no se presenta como cota.** Una versión anterior del texto la llamaba «cota»; FLC-O la iguala o supera, así que solo es una referencia empírica.
- **Saturación.** Al principio los controladores entrenados con caudales de hasta 3000 veh/h se degradaban cerca de la capacidad; entrenar con hasta 3300 lo evitó. El resultado final es empate con el actuado afinado, y así se declara; no se presenta como mejora.
- **Verde mínimo de 7 s.** Los primeros entrenamientos lo usaban y limitaban a los modelos (con 7 s, FLC-O da 8.55 s/veh en promedio de tres semillas); se estudió el rango de 3 a 7 s con la validación.
- **El hueco desde la última llegada** no ayudó (familia C), pese a ser la señal del actuado.

- **Modelos exploratorios** con otras condiciones se conservan en `resultados/opt/previos/` por transparencia; no se usan en el artículo ni son comparables.

10. Limitaciones

1. **Vista adelante.** FLC-O usa las llegadas de los próximos 10 s, un supuesto del original (equivale a detectores aguas arriba sin error). Sin ella, FLC-O causal da 9.97 s/veh, peor que el actuado afinado (9.63); la mejor variante causal, la red neuronal, lo supera solo en 1.7 %. Con vista adelante, FLC-O tiene un retardo 16.4 % menor que el de la mejor variante sin ella (9.46 s/veh). Es la limitación más importante: en la práctica los detectores tienen error y alcance limitado, y no se midió la robustez ante eso.
2. **Saturación.** Empate con el actuado afinado, no mejora.
3. **Verde mínimo de 3 s.** Puede no ser admisible por seguridad o norma; con 5 s el resultado es 8.19 s/veh (promedio de tres semillas).
4. **Simulación.** Un cruce aislado, llegadas de Bernoulli, flujo de saturación fijo, sin giros, peatones ni redes. Los parámetros se entrenan y se evalúan en el mismo simulador, aunque con caudales y semillas distintos. No hay datos de campo. Los modelos exploratorios (Sec. 9) guiaron el diseño de las familias de candidatos; por eso las decisiones finales se tomaron con la validación y se reportan todas las variantes, incluidas las peores.
5. **Alcance de las comparaciones.** El actuado afinado y la presión máxima se afinaron con rejillas finitas; no hay garantía de que sean los mejores de su clase. La red neuronal es de una arquitectura y un entrenamiento; otra podría superarla. No se comparó CMA-ES con otros optimizadores, ni se probaron bases de menos de 27 reglas ni el camino intermedio de optimizar también los conjuntos y consecuentes de las 25 reglas.
6. **Cifras del controlador de 1977.** Salen de nuestra simulación con las definiciones de A y Q de la Sec. 3, no de la Tabla VIII impresa, que se reproduce con un error medio de 9.2 % y máximo de 18.6 %.

11. Preguntas que podrían hacerse

¿Por qué no usar directamente la red neuronal? Rinde igual o peor (8.09 contra 7.91 s/veh; FLC-O es significativamente mejor en 11 de 16 pares), tiene tres veces más parámetros y no se puede leer ni auditar. Para un semáforo, que alguien pueda revisar por qué cambia de fase es una ventaja práctica.

¿Por qué CMA-ES y no un algoritmo genético u otro? Porque el objetivo es una simulación sin derivadas y CMA-ES es un método estándar para ese tipo de problema con decenas de parámetros [4]. No se comparó con otros; no se afirma que sea el mejor, solo que funciona y converge (Fig. 1).

¿Cómo sabemos que no hay sobreajuste? Porque se eligió con la validación y se probó en otros cuatro conjuntos; la brecha entre entrenamiento y validación es de 2.9 %, y la ventaja se mantiene con caudales no vistos (0.807 veces el actuado afinado) y con demanda variable (0.753).

¿Por qué los retardos no coinciden con los de la Tabla VIII del original? Porque el controlador de 1977 que se compara sale de nuestra simulación, con las definiciones de A y Q de la Sec. 3, y porque el original no da el número de réplicas ni el generador aleatorio. Esa simulación reproduce la tabla con un error medio de 9.2 % (máximo 18.6 %) y reproduce la conclusión del original: mejora al ciclo fijo en 16 de 16 pares. Además, aquí se cuenta la espera residual al final, que el original no precisa.

¿Por qué el verde mínimo es de 3 s? Porque fue el mejor en validación (Sec. 6). Es una elección de simulación; si hace falta más, con 5 s la mejora frente a Pappis y Mamdani sigue siendo de 25.2 % (promedio de tres semillas).

¿Por qué el controlador ve el futuro? Porque el modelo original ya lo supone (las llegadas de los próximos 10 s). Se mantuvo para comparar en las mismas condiciones y se midió cuánto depende de ello, que es mucho.

¿Se puede usar en una intersección real? No se afirma. Faltan datos de campo, errores de detección y los demás elementos de una intersección real (Sec. 10).

¿Por qué solo 25 reglas? ¿Son las óptimas? No se afirma que lo sean. Son las 25 reglas del artículo original (Apéndice) y se conservaron sin tocar como línea base, porque el trabajo consiste en mejorar ese sistema y hay que medir contra el original intacto; el propio original las obtuvo por prueba y error y habla de «satisficing control» (p. 714), no de un óptimo. La propuesta de este trabajo no usa esas 25 reglas: FLC-O tiene 27 reglas nuevas. Lo que sí se midió: afinar los números de las 25 reglas mejora 11.7 % y FLC-O mejora 27.8 %; y en la réplica, un experimento exploratorio (`resultados/ablacion_reglas.json`) mostró que quitar reglas a las 25 siempre empeoraba el retardo (con 20 reglas, 4.8 % más; con 15, 1.6 % más).

¿Por qué 27 reglas? ¿Son las óptimas? Tampoco se afirma. Se eligieron tres conjuntos (bajo, medio, alto) para cada una de tres variables, la partición más pequeña que distingue tres niveles de cada una. Se probó una base mayor, de 81 reglas al agregar una cuarta variable, y no mejoró (8.44 contra 8.47 s/veh de las 27 reglas con los mismos horizontes fijos, medias de tres semillas); esa comparación mezcla más reglas y más información. No se probaron bases de menos de 27 reglas ni otras estructuras, y no existe una cota que certifique que FLC-O sea el óptimo cuando se ve el futuro. Solo el caso sin vista adelante está acotado: la mejor variante queda a 9.46 contra 9.35 s/veh de la cota de programación dinámica, alrededor de 1.2 % por encima.

12. Reproducción y dónde está cada cosa

Con Python 3.13 y NumPy 2.5, desde la carpeta del proyecto:

- `python codigo/ejecutar_pruebas.py`: todas las comprobaciones.
- `python codigo/opt_validar.py` seguido de los nombres de los modelos: ordena candidatos con la validación.
- `python codigo/opt_evaluacion_final.py`: los cuatro conjuntos de prueba y la estadística.
- `python codigo/gen_tablas_opt.py` y `python codigo/gen_justificacion.py`: las cifras y tablas del artículo y de este documento.

Qué	Dónde
Simulador vectorizado y su prueba de equivalencia	`codigo/sim_batch.py`, `codigo/test_sim_batch.py`
Controladores (Pappis y Mamdani afinado, difusos, política neuronal, referencias)	`codigo/opt_controladores.py`, `opt_flc.py`, `opt_flc2.py`, `opt_politicas.py`
Optimizador CMA-ES	`codigo/opt_es.py`
Cota por programación dinámica	`codigo/opt_mdp.py`, `resultados/opt/mdp_oficial.json`
Entrenamiento y escenarios	`codigo/opt_entrenar.py`, `opt_entrenar_modelo.py`
Modelos entrenados y el elegido	`resultados/opt/flcopt_g3_s2.json` (el elegido) y `resultados/opt/modelos_finales.json`
Evaluación final y estadística	`codigo/opt_evaluacion_final.py`, `resultados/opt/evaluacion_final.json`
Rivales afinados	`resultados/opt/actuado_afinado.json` y `resultados/opt/maxpressure_afinado.json`
Simulador interactivo con calle y autos	`codigo/simulador_gui.py`, `codigo/web_sim.py`
Artículo, suplemento y este documento	`articulo/main.tex`, `suplemento.tex`, `justificacion.tex`

Fuente: repositorio del proyecto, rama `main`.

Referencias

[1] C. P. Pappis and E. H. Mamdani, "A fuzzy logic controller for a traffic junction," *IEEE Trans. Syst., Man, Cybern.*, vol. SMC-7, no. 10, pp. 707–716, Oct. 1977.

[2] J. D. C. Little, "A proof for the queuing formula: $L = \lambda W$," *Oper. Res.*, vol. 9, no. 3, pp. 383–387, 1961, doi:10.1287/opre.9.3.383.

[3] N. Hansen and A. Ostermeier, "Completely derandomized self-adaptation in evolution strategies," *Evol. Comput.*, vol. 9, no. 2, pp. 159–195, 2001.

[4] N. Hansen, "The CMA evolution strategy: A tutorial," arXiv:1604.00772, 2016.

[5] P. Varaiya, "Max pressure control of a network of signalized intersections," *Transp. Res. C, Emerg. Technol.*, vol. 36, pp. 177–195, 2013.

[6] M. L. Puterman, *Markov Decision Processes: Discrete Stochastic Dynamic Programming*. New York, NY, USA: Wiley, 1994.

[7] T. Takagi and M. Sugeno, "Fuzzy identification of systems and its applications to modeling and control," *IEEE Trans. Syst., Man, Cybern.*, vol. SMC-15, no. 1, pp. 116–132, Jan. 1985, doi:10.1109/TSMC.1985.6313399.